

赛题五：基于原始量价数据的股票收益预测

(1) 业务背景

在量化投资中，利用历史量价数据预测股票未来收益是核心研究课题之一。本次比赛提供全市场 A 股的日线级别量价数据，要求参赛选手构建预测模型，对测试集中每只股票每个交易日的未来一天收益率进行预测。

(2) 研究目标

对测试集中每条记录（ts_code + trade_date），预测其对应的 y_ret_1d（未来一天收益率）。

(3) 数据说明

3.1 数据文件

文件	说明
训练集.csv	包含特征 X 和标签 Y，供模型训练使用
测试集_X.csv	仅包含特征 X，供模型预测使用

3.2 字段定义

字段	类型	说明
ts_code	str	股票代码（如 000001.SZ、600000.SH）
trade_date	int	交易日期（如 20180102）
open	float	开盘价（后复权）
high	float	最高价（后复权）
low	float	最低价（后复权）
close	float	收盘价（后复权）

vol	float	成交量（股）
amount	float	成交额（元）
flag_limit_up	int	涨停标志（1 = 涨停，0 = 未涨停）
flag_limit_down	int	跌停标志（1 = 跌停，0 = 未跌停）
y_ret_1d	float	未来一天收益率 = $\text{close}(t+1) / \text{close}(t) - 1$ （仅训练集提供）

3.3 数据概况

项目	训练集	测试集
股票数量	4650	4650
数据行数	7,900,350	1,599,600
日期范围	20180102 ~ 20241231	20250102 ~ 20260608

3.4 数据特点

1. **价格已做后复权处理**：消除了送股、分红等事件导致的价格跳变，价格序列连续可直接用于计算技术指标。

2. **涨跌停标志**：flag_limit_up 和 flag_limit_down 标注了当日是否涨停 / 跌停，可用于过滤不可交易样本。

3. **Y 标签缺失**：训练集中 y_ret_1d 存在约 14.5% 的缺失值（NaN），主要来自股票停牌、未上市等情况，选手需自行处理。

（4）产出要求

参赛团队需提交一份数据分析报告，包括：（1）数据介绍；（2）描述性分析；（3）模型分析；（4）应用验证；（5）产品思路；（6）总结结论。

页数要求：正文不超过 8 页，详细排版要求详见报名课堂派报名说明。

此外，还需要提交预测结果文件 submission.csv，其格式要求如下：

submission.csv 包含以下字段：

字段	说明
ts_code	与测试集_X.csv 中的 ts_code 一致
trade_date	与测试集_X.csv 中的 trade_date 一致
pred	预测的未来一天收益率

示例：

```
ts_code,trade_date,pred
000001.SZ,20250102,0.0052
000001.SZ,20250103,-0.0031
...
```

（5）评价标准

采用多维度加权打分方式综合评估选手预测能力，提供 python 和 R 两个版本的评价指标计算方式

评价指标计算附件

[Python 评价指标计算方式 \(evaluate.py\)](#)

[R 评价指标计算方式 \(evaluate.R\)](#)

5.1 评价指标

指标	权重	说明
Rank IC	40%	逐日截面 Spearman 秩相关系数的均值
Top 组超额收益	30%	剔除涨停股后，Top1 组平均收益减去全市场平均收益（年化）
预测换手率	30%	Top1 组持仓相邻日的 Jaccard 距离，越低越好

5.2 指标计算规则

（a）Rank IC（权重 40%）

对测试集中每个交易日 t：

1. 取当日所有股票的 pred 和 y_ret_1d (剔除 y_ret_1d 为 NaN 的样本)
2. 计算 Spearman 秩相关系数: $IC_t = \text{spearman}(\text{pred}_t, y_ret_1d_t)$
最终指标: $IC_mean = \text{mean}(IC_1, IC_2, \dots, IC_T)$

(b) Top 组超额收益 (权重 30%)

对测试集中每个交易日 t:

1. 剔除当日涨停股 ($\text{flag_limit_up} == 1$), 因为涨停股无法买入
2. 剔除 y_ret_1d 为 NaN 的样本
3. 将剩余股票按 pred 降序排列, 等分为 10 组
4. Top1 组当日收益 = Top1 组 y_ret_1d 的均值
5. 全市场当日收益 = 全部剩余股票 y_ret_1d 的均值
6. 超额收益_t = Top1 组当日收益 - 全市场当日收益

最终指标: 年化超额收益 = $\text{mean}(\text{超额收益}_1, \dots, \text{超额收益}_T) \times 252$

(c) 预测换手率 (权重 30%)

对测试集中每个交易日 t (从第 2 天开始):

1. 剔除当日涨停股 ($\text{flag_limit_up} == 1$)
2. 将剩余股票按 pred 降序排列, 取 Top1 组 (前 10%) 的股票集合 Set_t
3. 计算相邻日换手率:
$$\text{turnover}_t = 1 - |\text{Set}_t \cap \text{Set}_{t-1}| / |\text{Set}_t \cup \text{Set}_{t-1}|$$

最终指标: $\text{mean_turnover} = \text{mean}(\text{turnover}_2, \text{turnover}_3, \dots, \text{turnover}_T)$
(越低表示预测越稳定, 换手成本越低)

5.3 综合评分

最终得分 = $IC_mean \times 40\% + \text{年化超额收益} \times 30\% + (1 - \text{mean_turnover}) \times 30\%$

说明:

- IC_mean: 越高越好, 取值范围通常 $[-0.1, 0.1]$
- 年化超额收益: 越高越好, 取值范围通常 $[-0.5, 0.5]$
- $(1 - \text{mean_turnover})$: 换手率越低得分越高, 取值范围 $[0, 1]$

5.4 辅助参考指标

以下指标仅作参考, 不计入最终总分:

- ICIR = IC 均值 / IC 标准差
- Rank IC > 0 的交易日占比

- Top1 组年化绝对收益率
- Top1 - Bottom1 多空收益差（年化）

（6）注意事项

1. 特征工程只能基于训练集 / 测试集中的字段，禁止使用未来信息。
2. 测试集的 Y 标签仅在赛后用于评分，比赛期间不对外提供。
3. 选手可自由使用开源工具和模型框架。
4. 训练集 Y 标签的缺失值（NaN）需选手自行处理（如删除、填充等）。